

Pareto Frontier: Prefill vs Decode Latency

