

Roofline — LLaMA-70B | prefill | BS=32 SL=1024 | 4x GPU

